

Analiza Danych Obrazowych i Multimedialnych

zima 2025/26

dr hab.inż. Marcin Iwanowski

1 Organizacja przedmiotu

1.1 Opis przedmiotu

Analiza Danych Obrazowych i Multimedialnych to przedmiot projektowy poświęcony metodom komputerowej analizy obrazów, wideo oraz danych multimodalnych, obejmujący zarówno klasyczne algorytmy przetwarzania obrazu, jak i współczesne modele uczenia głębokiego i multimodalnego. Celem przedmiotu jest zrozumienie zasad działania kluczowych metod reprezentacji, detekcji, segmentacji, klasyfikacji oraz generowania treści wizualnych i audiowizualnych, a także zdobycie praktycznych umiejętności ich implementacji, uruchamiania i oceny eksperymentalnej. Zajęcia mają charakter zespołowych projektów badawczo-implementacyjnych, w których studenci pracują w grupach nad wybranym artykułem naukowym stanowiącym kamień milowy w rozwoju dziedziny.

Każdy zespół analizuje artykuł, uruchamia dostępne repozytorium kodu, przygotowuje własne demo oraz przeprowadza serię eksperymentów badających wpływ parametrów modelu, jakości danych oraz przyjętych założeń na uzyskiwane wyniki. Szczególny nacisk położony jest na interpretację wyników, analizę przypadków błędnych oraz ocenę ograniczeń metody. Tematy projektów obejmują m.in. klasyczne algorytmy ekstrakcji cech (Canny, SIFT, HOG), reprezentacje obrazów i wyszukiwanie podobieństwa, głębokie sieci konwolucyjne (AlexNet, VGG, ResNet), segmentację (U-Net), detekcję obiektów (Faster R-CNN, YOLO), modele generatywne (GAN), modele sekwencyjne i transformery, a także współczesne modele multimodalne (CLIP, image captioning).

Realizacja projektów odbywa się w środowisku Python z wykorzystaniem bibliotek takich jak PyTorch, OpenCV i Hugging Face. Wersja podstawowa przedmiotu jest dostosowana do pracy na komputerach bez akceleracji GPU, natomiast dla zainteresowanych zespołów przewidziane są opcjonalne rozszerzenia wykorzystujące akceleratory sprzętowe. Zaliczenie przedmiotu obejmuje przygotowanie repozytorium projektu, przeprowadzenie udokumentowanych eksperymentów oraz prezentację wyników w formie seminarium z demonstracją działania opracowanego systemu. Po ukończeniu kursu student posiada praktyczne umiejętności analizy współczesnych publikacji z zakresu computer vision i multimodal AI, implementacji modeli oraz krytycznej oceny ich właściwości i ograniczeń.

1.2 Charakter przedmiotu

Zajęcia mają charakter projektowo-seminaryjny. Studenci pracują w zespołach 4-osobowych. Każdy zespół realizuje jeden temat oparty na kluczowym artykule naukowym z zakresu tematyckiego przedmiotu oraz istniejącym repozytorium kodu.

Celem projektu jest:

- dogłębne zrozumienie metody (model matematyczny, pipeline),

- uruchomienie i uporządkowanie kodu,
- zaprojektowanie i wykonanie eksperymentów,
- analiza krytyczna wyników,
- przygotowanie 30-minutowej prezentacji przybliżającej metodę.

1.3 Role w zespole

1. **Theory Lead** – analiza artykułu, formalizacja matematyczna, ograniczenia, prezentacja krótka.
2. **Implementation Lead** – uruchomienie repo, refaktoryzacja, środowisko.
3. **Experiments Lead** – projekt eksperymentów, metryki.
4. **Presentation/demo Lead** – demo, integracja kodu, prezentacja długa.

1.4 Wymagane artefakty

1. prezentacja krótka (slajdy na 10 min wprowadzenia do tematu)
2. prezentacja długa (slajdy na 30 min omawiania tematu)
3. repozytorium Git, które musi zawierać:
 - README (cel, instalacja, uruchomienie),
 - requirements.txt lub environment.yml,
 - kod treningu i ewaluacji,
 - notebook demonstracyjny,
 - wyniki i raport eksperymentów (minimum 3 eksperymenty, np. 2 zmiany parametrów + porównanie z baseline).

1.5 Kryteria oceniania (100 pkt)

Prezentacja krótka – 10 min (P)	5 pkt
Prezentacja długa – 30 min (P)	20 pkt
Prezentacja długa – 30 min (S)	10 pkt
Demo i jakość kodu (P)	20 pkt
Demo i jakość kodu (S)	10 pkt
Eksperymenty (P)	25 pkt
Obecność	10 pkt

P	ocena zespołu przez prowadzącego (M.I.)
S	ocena prezentacji długiej przez ogół studentów lub kodu przez zespół weryfikujący

1.6 Harmonogram lato 25/26

24.02	14:15 - 15:45	spotkanie informacyjne - ob.
3.03	14:15 - 15:45	wykład wprowadzający 1 (M.I.) - ob.
10.03	14:15 - 15:45	wykład wprowadzający 2 (M.I.) - ob.
17.03	14:15 - 15:45	wykład wprowadzający 3 (M.I.) - ob.
24.03	10:15 - 11:45	<i>konsultacje eksperymentów zesp.1-8</i>
24.03	14:15 - 15:45	prezentacje krótkie zesp. 1-8 - ob.
31.03	10:15 - 11:45	<i>konsultacje eksperymentów zesp.9-16</i>
31.03	14:15 - 15:45	prezentacje krótkie zesp. 9-16 - ob.
19.05	14:15 - 15:45	<i>weryfikacja eksperymentów zesp.1-8</i>
26.05	14:15 - 15:45	<i>weryfikacja eksperymentów zesp.9-16</i>
2.06	14:15 - 19:15	prezentacje długie zesp. 1-8 - 2 x ob.
9.06	14:15 - 19:15	prezentacje długie zesp. 9-16 -2 x ob.

ob. - zajęcia, na których będzie sprawdzana obecność

1.7 Komunikacja w ramach przedmiotu

Głównym kanałem komunikacyjnym jest zespół 'ADOM 26L' na MSTEams.

2 Tematy

2.1 TEMAT 1 - Detekcja krawędzi – Canny edge detector (1986)

Artykuł: <https://www.cs.ubc.ca/~lowe/425/papers/canny.pdf>

Repozytorium: https://docs.opencv.org/4.x/da/d22/tutorial_py_canny.html

Opis: Metoda Canny’ego jest jednym z najważniejszych klasycznych algorytmów detekcji krawędzi w obrazach cyfrowych i stanowi fundament wielu systemów analizy obrazu. Jej celem jest identyfikacja punktów, w których występują istotne zmiany intensywności, odpowiadające granicom obiektów. Algorytm składa się z kilku etapów obejmujących wygładzanie obrazu filtrem Gaussa w celu redukcji szumu, obliczenie gradientu, selekcję lokalnych maksimów (non-maximum suppression) oraz progowanie z histerezą. Takie podejście pozwala uzyskać cienkie, ciągłe i dobrze zlokalizowane krawędzie przy jednoczesnym ograniczeniu liczby detekcji fałszywych. Istotną cechą metody jest możliwość regulacji jej działania poprzez dobór parametrów progowania i poziomu wygładzania. Algorytm Canny’ego jest szeroko stosowany jako etap wstępny w zadaniach segmentacji, rekonstrukcji sceny, detekcji obiektów oraz dopasowania obrazów. Zrozumienie jego działania stanowi wprowadzenie do pojęć gradientu obrazu, filtracji oraz kompromisu między czułością detekcji a odpornością na szum.

Plan eksperymentów

- Demo: interaktywny suwak progów i sigma.
- Test: siatka progów (min 20 kombinacji).
- Dodanie szumu (Gaussian, salt&pepper).
- Porównanie z Sobel i Scharr.
- Raport: precision/recall względem maski referencyjnej.

2.2 TEMAT 2 - Detekcja twarzy – Viola–Jones (2001)

Artykuł: <https://www.cs.cmu.edu/~efros/courses/LBMV07/Papers/viola-cvpr-01.pdf>

Repozytorium: https://docs.opencv.org/4.x/db/d28/tutorial_cascade_classifier.html

Opis: Algorytm Viola–Jones jest jedną z pierwszych metod umożliwiających detekcję obiektów, w szczególności twarzy, w czasie rzeczywistym. Wykorzystuje proste cechy Haar opisujące lokalne kontrasty jasności, które mogą być bardzo szybko obliczane dzięki zastosowaniu obrazu całkowego (integral image). Kluczowym elementem metody jest zastosowanie algorytmu boosting do wyboru najbardziej informatywnych cech oraz zbudowania klasyfikatora złożonego z wielu prostych decyzji. Klasyfikator ten jest zorganizowany w strukturę kaskadową, co pozwala szybko odrzucać większość fragmentów obrazu niezawierających obiektu i koncentrować obliczenia na obszarach potencjalnie istotnych. Dzięki temu rozwiązaniu metoda osiąga wysoką szybkość działania nawet na ograniczonym sprzęcie. Algorytm był szeroko stosowany w aparatach cyfrowych, systemach monitoringu oraz interfejsach użytkownika opartych na analizie obrazu. Jego analiza pozwala zrozumieć zasady klasyfikacji opartej na cechach ręcznie projektowanych oraz kompromis między dokładnością a złożonością obliczeniową.

Plan eksperymentów

- Demo: detekcja z kamery.

- Zmiana scaleFactor i minNeighbors.
- Test przy słabym oświetleniu.
- Porównanie z RetinaFace (inference).
- Metryki: Precision, Recall, FPS.

2.3 TEMAT 3 - Reprezentacja obrazu – Bag of Visual Words (2003)

Artykuł: <https://www.robots.ox.ac.uk/~vgg/publications/2003/Sivic03/sivic03.pdf>

Repozytorium: <https://github.com/mbeyeler/opencv-python-blueprints>

Opis: Model Bag of Visual Words (BoVW) jest klasyczną metodą reprezentacji obrazów inspirowaną podejściem bag-of-words stosowanym w analizie tekstu. Polega on na opisanu obrazu jako histogramu występowania lokalnych cech wizualnych, które są wcześniej grupowane w klastry tworzące tzw. słownik wizualny. Każdy obraz jest reprezentowany przez wektor częstości występowania tych elementów, co umożliwia jego porównywanie z innymi obrazami przy użyciu standardowych miar podobieństwa. Podejście to pozwala przekształcić problem analizy obrazu w problem klasyfikacji lub wyszukiwania w przestrzeni wektorowej. Metoda była szeroko stosowana w systemach wyszukiwania obrazów i wczesnych systemach rozpoznawania obiektów. Jej skuteczność zależy od sposobu ekstrakcji cech oraz liczby elementów w słowniku wizualnym. Analiza tej metody pozwala zrozumieć koncepcję reprezentacji cech, kwantyzacji wektorów oraz podstaw działania systemów wyszukiwania wizualnego.

Plan eksperymentów

- Demo: wyszukiwanie top-k.
- Test różnych k (50,100,500).
- TF vs TF-IDF.
- Porównanie cosine vs L2.
- Metryki: mAP, Recall@k.

2.4 TEMAT 4 - Dopasowanie obrazów – Scale-Invariant Feature Transform (2004)

Artykuł: <https://link.springer.com/content/pdf/10.1023/B:VISI.0000029664.99615.94.pdf>

Repozytorium: https://docs.opencv.org/4.x/da/df5/tutorial_py_sift_intro.html

Opis: Scale-Invariant Feature Transform (SIFT) jest jedną z najważniejszych metod wykrywania i opisu punktów charakterystycznych w obrazach cyfrowych. Algorytm identyfikuje stabilne punkty kluczowe w przestrzeni skali, które są odporne na zmiany rozdzielczości, rotację oraz umiarkowane zmiany oświetlenia. Dla każdego punktu wyznaczany jest deskryptor opisujący lokalną strukturę gradientów w jego otoczeniu, co umożliwia jednoznaczne dopasowanie punktów pomiędzy różnymi obrazami. Dzięki temu możliwe jest znajdowanie odpowiadających sobie fragmentów sceny nawet przy zmianie punktu widzenia kamery. Metoda ta stanowi podstawę wielu zastosowań, takich jak rejestracja obrazów, tworzenie panoram, rekonstrukcja 3D oraz wyszukiwanie obrazów. Kluczową cechą algorytmu jest jego odporność na transformacje geometryczne

oraz częściowe zasłonięcia obiektów. Deskryptory mogą być porównywane przy użyciu miar odległości w przestrzeni wektorowej, co pozwala określić stopień podobieństwa obrazów. Analiza metody SIFT pozwala zrozumieć pojęcie cech lokalnych oraz ich znaczenie w zadaniach dopasowania i rozpoznawania obrazów.

Plan eksperymentów

- Demo: dopasowanie dwóch zdjęć + wizualizacja matchy.
- Rotacja i skalowanie jednego obrazu.
- Estymacja homografii (RANSAC).
- Porównanie z ORB.
- Metryki: liczba inlierów, reprojection error.

2.5 TEMAT 5 - Detekcja obiektów – HOG + SVM (2005)

Artykuł: <https://lear.inrialpes.fr/people/triggs/pubs/Dalal-cvpr05.pdf>

Repozytorium: https://scikit-image.org/docs/stable/auto_examples/features_detection/plot_hog.html

Opis: Histogram of Oriented Gradients (HOG) jest metodą opisu obrazu opartą na analizie rozkładu orientacji gradientów w lokalnych obszarach obrazu. Deskryptor ten pozwala uchwycić charakterystyczną strukturę krawędzi i konturów, które są kluczowe dla rozpoznawania kształtu obiektów. Obraz dzielony jest na małe komórki, w których obliczane są histogramy kierunków gradientu, a następnie normalizowane w większych blokach w celu zwiększenia odporności na zmiany oświetlenia. Uzyskana reprezentacja może być wykorzystana jako wejście do klasyfikatora, najczęściej liniowego SVM, który decyduje o obecności obiektu w analizowanym fragmencie obrazu. Metoda ta była szeroko stosowana w zadaniach detekcji pieszych oraz innych obiektów przed upowszechnieniem sieci konwolucyjnych. Jej zaletą jest stosunkowo niska złożoność obliczeniowa oraz dobra interpretowalność reprezentacji cech. Analiza podejścia HOG+SVM pozwala zrozumieć klasyczny pipeline detekcji obiektów oparty na ręcznie projektowanych cechach i klasyfikatorze nadzorowanym.

Plan eksperymentów

- Demo: sliding window.
- Parametry HOG (orientations, cell size).
- Zmiana rozmiaru okna.
- Porównanie z małym CNN (opcjonalnie).
- Metryki: F1, ROC.

2.6 TEMAT 6 - Klasyfikacja obrazów – AlexNet (2012)

Artykuł: <https://proceedings.neurips.cc/paper/2012/file/c399862d3b9d6b76c8436e924a68c45b-Paper.pdf>

Repozytorium: <https://pytorch.org/vision/stable/models/alexnet.html>

Opis: AlexNet jest jedną z pierwszych głębokich sieci konwolucyjnych, które osiągnęły przełomowe wyniki w zadaniu klasyfikacji obrazów na dużą skalę. Architektura składa się z wielu warstw konwolucyjnych odpowiedzialnych za automatyczne uczenie hierarchicznych reprezentacji cech, od prostych krawędzi po złożone struktury obiektów. Wprowadzenie funkcji aktywacji ReLU umożliwiło skuteczniejsze uczenie głębokich modeli poprzez ograniczenie problemu zanikania gradientu. Zastosowanie technik takich jak dropout i augmentacja danych pozwoliło zmniejszyć przeuczenie i poprawić zdolność generalizacji modelu. Model został wytrenowany na zbiorze ImageNet i znacząco przewyższył wcześniejsze metody oparte na ręcznie projektowanych cechach. AlexNet pokazał, że reprezentacje cech mogą być automatycznie uczone bez konieczności ich ręcznego projektowania. Architektura ta zapoczątkowała gwałtowny rozwój metod uczenia głębokiego w computer vision. Analiza tego modelu pozwala zrozumieć podstawowe elementy współczesnych sieci konwolucyjnych oraz ideę transfer learningu.

Plan eksperymentów

- Demo: fine-tuning classifier.
- Zamrożony vs częściowo odmrożony backbone.
- Augmentacje.
- Analiza błędów (confusion matrix).
- Raport czasu epoki.

Rozszerzenie GPU: pełny fine-tuning backbone + większa rozdzielczość.

2.7 TEMAT 7 - Głębokie CNN – VGG (2014)

Artykuł: <https://arxiv.org/pdf/1409.1556.pdf>

Repozytorium: <https://pytorch.org/vision/stable/models/vgg.html>

Opis: Architektura VGG stanowi rozwinięcie idei głębokich sieci konwolucyjnych poprzez systematyczne zwiększenie liczby warstw przy zachowaniu prostych filtrów o rozmiarze 3×3 . Zastosowanie wielu kolejnych małych filtrów pozwala uzyskać dużą efektywną szerokość pola recepcyjnego przy jednoczesnym ograniczeniu liczby parametrów w pojedynczej warstwie. Model charakteryzuje się regularną, powtarzalną strukturą bloków konwolucyjnych, co czyni go architekturą przejrzystą i łatwą do analizy. W porównaniu do AlexNet, VGG znacząco zwiększa głębokość sieci, co przekłada się na lepszą jakość reprezentacji cech wizualnych. Jednocześnie wiąże się to ze znacznym wzrostem liczby parametrów oraz kosztu obliczeniowego. VGG stał się jednym z najczęściej wykorzystywanych modeli bazowych (backbone) w wielu zadaniach wizji komputerowej. Analiza tej architektury pozwala zrozumieć wpływ głębokości sieci na jakość reprezentacji oraz ograniczenia wynikające z rosnącej złożoności modelu.

Plan eksperymentów

- VGG16 vs AlexNet.
- Dropout włączony/wyłączony.
- Analiza feature maps.
- Pomiar pamięci RAM.

Rozszerzenie GPU: pełny fine-tuning + analiza warstw głębokich.

2.8 TEMAT 8 - Generowanie opisów obrazów – Show and Tell (2014)

Artykuł: <https://arxiv.org/pdf/1411.4555.pdf>

Repozytorium: <https://github.com/sgrvinod/a-PyTorch-Tutorial-to-Image-Captioning>

Opis: Model Show and Tell jest jednym z pierwszych skutecznych podejść do automatycznego generowania opisów tekstowych na podstawie obrazów. Architektura łączy sieć konwolucyjną, która pełni rolę ekstraktora cech wizualnych, z siecią rekurencyjną odpowiedzialną za generowanie sekwencji słów opisujących obraz. Wektor cech obrazu jest wykorzystywany jako wejście modelu językowego, który przewiduje kolejne słowa opisu w sposób sekwencyjny. Dzięki temu możliwe jest automatyczne tworzenie zdań opisujących zawartość sceny, obecne obiekty oraz relacje między nimi. Model został wytrenowany na dużych zbiorach zawierających obrazy wraz z opisami tekstowymi, co pozwoliło mu nauczyć się powiązań między reprezentacją wizualną a językiem naturalnym. Podejście to zapoczątkowało intensywny rozwój metod multimodalnych łączących analizę obrazu i przetwarzanie języka naturalnego. Zadanie generowania opisów obrazów jest szczególnie wymagające, ponieważ wymaga zarówno rozpoznania obiektów, jak i zrozumienia ich kontekstu. Analiza tego modelu pozwala zrozumieć sposób integracji reprezentacji wizualnych z modelami sekwencyjnymi oraz podstawy współczesnych systemów multimodalnych.

Plan eksperymentów (CPU-only):

- Demo: inference pretrained model – generowanie opisu dla własnych obrazów.
- Analiza błędnych opisów (halucynacje obiektów).
- Modyfikacja długości generowanej sekwencji.
- Porównanie greedy decoding vs beam search (mały beam).
- Metryki: BLEU (na małym zbiorze testowym).

Rozszerzenie GPU:

- Fine-tuning na podzbiorze MS COCO.
- Dodanie mechanizmu uwagi.
- Porównanie z modelem Transformer-based captioning.

2.9 TEMAT 9 - Generowanie obrazów – GAN (2014)

Artykuł: <https://arxiv.org/pdf/1406.2661.pdf>

Repozytorium: <https://github.com/pytorch/examples/tree/main/dcgan>

Opis: Generative Adversarial Networks (GAN) to klasa modeli generatywnych zdolnych do tworzenia nowych danych o rozkładzie podobnym do danych uczących. Architektura składa się z dwóch sieci neuronowych: generatora, który tworzy syntetyczne próbki, oraz dyskryminatora, który próbuje odróżnić dane wygenerowane od rzeczywistych. Obie sieci są trenowane jednocześnie w procesie przypominającym grę o sumie zerowej, co prowadzi do stopniowej poprawy jakości generowanych danych. W wyniku uczenia generator uczy się odwzorowywać losowy wektor wejściowy na realistyczne obrazy. Modele GAN znalazły zastosowanie w generowaniu obrazów, poprawie jakości danych, symulacji danych treningowych oraz przetwarzaniu obrazu. Jednym z głównych wyzwań związanych z GAN jest niestabilność procesu uczenia oraz zjawisko tzw. mode

collapse. Podejście to zapoczątkowało dynamiczny rozwój generatywnych metod uczenia głębokiego. Analiza modelu GAN pozwala zrozumieć podstawy modeli generatywnych oraz znaczenie uczenia przeciwnego w sztucznej inteligencji.

Plan eksperymentów

- MNIST 28×28 .
- Zmiana learning rate.
- Wykrywanie mode collapse.
- Analiza latent space.

Rozszerzenie GPU: CIFAR + WGAN-GP + FID.

2.10 TEMAT 10 - Głębokie sieci rezydualne – ResNet (2015)

Artykuł: <https://arxiv.org/pdf/1512.03385.pdf>

Repozytorium: <https://pytorch.org/vision/stable/models/resnet.html>

Opis: Architektura ResNet wprowadza koncepcję połączeń skrótowych (residual connections), które umożliwiają efektywne trenowanie bardzo głębokich sieci neuronowych. Zamiast uczyć się bezpośredniego odwzorowania między wejściem a wyjściem warstwy, model uczy się jedynie różnicy między nimi, co znacząco ułatwia optymalizację. Rozwiązanie to ogranicza problem zanikania gradientu, który wcześniej utrudniał trenowanie głębokich modeli. Dzięki temu możliwe stało się budowanie sieci o kilkudziesięciu, a nawet kilkuset warstwach. ResNet osiągnął przełomowe wyniki w zadaniu klasyfikacji obrazów ImageNet i szybko stał się standardowym elementem wielu systemów wizji komputerowej. Architektura ta jest powszechnie wykorzystywana jako tzw. backbone w zadaniach detekcji obiektów, segmentacji i rozpoznawania obrazów. Połączenia rezydualne poprawiają zarówno stabilność uczenia, jak i zdolność modelu do reprezentowania złożonych struktur wizualnych. Analiza ResNet pozwala zrozumieć mechanizmy umożliwiające trenowanie bardzo głębokich modeli oraz ich znaczenie we współczesnych systemach uczenia głębokiego.

Plan eksperymentów

- ResNet18 CPU.
- Zamrażanie bloków.
- Scheduler learning rate.
- Analiza overfittingu.

Rozszerzenie GPU: ResNet50/101 + większy zbiór danych.

2.11 TEMAT 11 - Segmentacja obrazów – U-Net (2015)

Artykuł: <https://arxiv.org/pdf/1505.04597.pdf>

Repozytorium: <https://github.com/milesial/Pytorch-UNet>

Opis: U-Net jest architekturą sieci neuronowej zaprojektowaną do zadania segmentacji obrazów, czyli przypisywania etykiety do każdego piksela obrazu. Model ma strukturę typu encoder-decoder, w której część kodująca stopniowo zmniejsza rozdzielczość obrazu, ucząc się coraz

bardziej abstrakcyjnych cech, natomiast część dekodująca odtwarza szczegółową strukturę przestrzenną. Kluczowym elementem architektury są połączenia typu skip connections, które przekazują informacje o wysokiej rozdzielczości bezpośrednio z warstw kodujących do dekodujących. Dzięki temu możliwe jest jednoczesne wykorzystanie informacji globalnej i lokalnej, co poprawia dokładność segmentacji. Model został pierwotnie opracowany do analizy obrazów medycznych, gdzie precyzyjne wyznaczenie granic struktur ma kluczowe znaczenie. U-Net może być stosowany również w segmentacji scen drogowych, obrazów satelitarnych oraz innych danych wizualnych. Architektura ta stanowi podstawę wielu współczesnych modeli segmentacji. Analiza U-Net pozwala zrozumieć różnice między klasyfikacją obrazu a predykcją gęstą oraz znaczenie architektur encoder-decoder w wizji komputerowej.

Plan eksperymentów

- Segmentacja binarna 128×128 .
- BCE vs Dice loss.
- Augmentacje.
- Analiza błędów na granicach obiektów.

Rozszerzenie GPU: większa rozdzielczość + segmentacja wieloklasowa.

2.12 TEMAT 12 - Detekcja obiektów – Faster R-CNN (2015)

Artykuł: <https://arxiv.org/pdf/1506.01497.pdf>

Repozytorium: https://pytorch.org/tutorials/intermediate/torchvision_tutorial.html

Opis: Faster R-CNN jest jedną z najważniejszych architektur detekcji obiektów opartych na podejściu dwustopniowym. Model najpierw generuje propozycje potencjalnych lokalizacji obiektów przy użyciu sieci Region Proposal Network (RPN), a następnie klasyfikuje te regiony i precyzyjnie wyznacza ich granice. Dzięki integracji generowania propozycji z siecią neuronową metoda znacząco przyspieszyła wcześniejsze podejścia wykorzystujące zewnętrzne algorytmy generowania regionów. Architektura wykorzystuje głęboką sieć konwolucyjną jako ekstraktor cech wspólny dla obu etapów detekcji. Faster R-CNN osiąga bardzo wysoką dokładność lokalizacji i klasyfikacji obiektów na obrazach. Metoda ta stała się standardowym punktem odniesienia dla wielu późniejszych systemów detekcji obiektów. Jej głównym ograniczeniem jest stosunkowo wysoki koszt obliczeniowy w porównaniu do metod jednoetapowych. Analiza Faster R-CNN pozwala zrozumieć pełny pipeline detekcji obiektów oraz rolę reprezentacji cech w zadaniach lokalizacji i rozpoznawania.

Plan eksperymentów

- Inference pretrained.
- Zmiana confidence threshold.
- Analiza false positives.
- Porównanie z YOLO.

Rozszerzenie GPU: fine-tuning na własnym zbiorze.

2.13 TEMAT 13 - Detekcja jednoetapowa – YOLO (2016)

Artykuł: <https://arxiv.org/pdf/1506.02640.pdf>

Repozytorium: <https://github.com/ultralytics/ultralytics>

Opis: YOLO jest architekturą detekcji obiektów opartą na podejściu jednoetapowym, w którym lokalizacja i klasyfikacja obiektów są realizowane w jednym przebiegu sieci neuronowej. Obraz jest dzielony na siatkę, a dla każdej jej komórki model jednocześnie przewiduje obecność obiektów, ich klasy oraz współrzędne prostokątów ograniczających. Takie podejście znacząco upraszcza pipeline detekcji i umożliwia działanie w czasie rzeczywistym. W porównaniu do metod dwustopniowych, takich jak Faster R-CNN, YOLO oferuje znacznie większą szybkość kosztem nieco niższej dokładności w niektórych przypadkach. Architektura ta była szeroko stosowana w systemach monitoringu, robotyce i pojazdach autonomicznych. Kolejne wersje modelu wprowadzały istotne ulepszenia zarówno w zakresie dokładności, jak i wydajności. YOLO pokazuje, że detekcja obiektów może być traktowana jako problem regresji zamiast klasycznego pipeline'u wieloetapowego. Analiza tej metody pozwala zrozumieć kompromis między szybkością działania a dokładnością modeli detekcyjnych.

Plan eksperymentów

- Demo realtime.
- Pomiar FPS CPU.
- Zmiana imgsz.
- Analiza małych obiektów.

Rozszerzenie GPU: fine-tuning + większa rozdzielczość.

2.14 TEMAT 14 - Generowanie audio – WaveNet (2016)

Artykuł: <https://arxiv.org/pdf/1609.03499.pdf>

Repozytorium: <https://github.com/ibab/tensorflow-wavenet>

Opis: WaveNet jest modelem generatywnym zaprojektowanym do bezpośredniego modelowania i generowania sygnałów audio w dziedzinie czasu. Architektura wykorzystuje konwolucje przyczynowe i rozszerzane (dilated convolutions), które umożliwiają modelowanie zależności długoterminowych bez konieczności stosowania sieci rekurencyjnych. Model przewiduje kolejne próbki sygnału na podstawie wcześniej wygenerowanych wartości, co pozwala uzyskać bardzo realistyczną syntezę dźwięku. Podejście to zostało zastosowane m.in. w systemach syntezy mowy, osiągając jakość zbliżoną do nagrań ludzkich. WaveNet pokazuje, że modele głębokiego uczenia mogą skutecznie reprezentować złożone sygnały ciągłe. Jednocześnie generowanie sygnału jest procesem obliczeniowo kosztownym ze względu na jego sekwencyjny charakter. Analiza tej architektury pozwala zrozumieć zastosowanie konwolucji w modelowaniu sekwencji oraz podstawy generatywnych modeli sygnałów czasowych.

Plan eksperymentów

- Uproszczony model Conv1D.
- Generacja krótkiej próbki.
- Pomiar czasu generacji.

Rozszerzenie GPU: pełna architektura + długie sekwencje.

2.15 TEMAT 15 - Modele językowe – Transformatory (2017)

Artykuł: <https://arxiv.org/pdf/1706.03762.pdf>

Repozytorium: <https://github.com/huggingface/transformers>

Opis: Transformer jest architekturą sieci neuronowej zaprojektowaną do modelowania danych sekwencyjnych przy użyciu mechanizmu self-attention. W przeciwieństwie do wcześniejszych modeli rekurencyjnych, umożliwia równoległe przetwarzanie całej sekwencji, co znacząco przyspiesza uczenie i wnioskowanie. Mechanizm attention pozwala modelowi dynamicznie określać, które elementy sekwencji są najważniejsze przy przewidywaniu danego wyjścia. Architektura składa się z bloków attention oraz warstw w pełni połączonych, które wspólnie tworzą bogatą reprezentację danych. Model ten stał się podstawą współczesnych systemów przetwarzania języka naturalnego, w tym dużych modeli językowych. Koncepcja attention została również zastosowana w wielu zadaniach wizji komputerowej i analizy multimodalnej. Transformer umożliwia modelowanie złożonych zależności między elementami danych bez konieczności stosowania konwolucji lub rekurencji. Analiza tej architektury pozwala zrozumieć podstawy współczesnych modeli sekwencyjnych oraz rolę mechanizmów attention w uczeniu reprezentacji.

Plan eksperymentów

- DistilBERT fine-tuning.
- Zmiana długości sekwencji.
- Analiza attention map.

Rozszerzenie GPU: BERT-base + większe dane.

2.16 TEMAT 16 - Transformatory wizyjne – Vision Transformer (2020)

Artykuł: <https://arxiv.org/pdf/2010.11929.pdf>

Repozytorium: https://github.com/google-research/vision_transformer

Opis: Vision Transformer jest architekturą przeznaczoną do analizy obrazów, która wykorzystuje mechanizm self-attention zamiast klasycznych operacji konwolucyjnych. Obraz jest dzielony na małe fragmenty o stałym rozmiarze, zwane patchami, które są następnie przekształcane w sekwencję wektorów wejściowych modelu. Sekwencja ta jest przetwarzana przez architekturę transformera, która uczy się relacji między różnymi częściami obrazu. Podejście to umożliwia modelowanie zależności globalnych już na wczesnych etapach przetwarzania. Vision Transformer osiągnął wyniki porównywalne lub lepsze niż klasyczne sieci konwolucyjne przy odpowiednio dużych zbiorach danych. Model ten stanowi alternatywę dla architektur opartych na konwolucjach w zadaniach klasyfikacji obrazów. Podejście to zapoczątkowało rozwój wielu transformerowych architektur wizualnych. Analiza Vision Transformer pozwala zrozumieć różnice między podejściem konwolucyjnym a transformerowym w reprezentacji danych wizualnych.

Plan eksperymentów

- ViT-tiny inference.
- Porównanie z ResNet18.
- Analiza patch size.

Rozszerzenie GPU: pełny fine-tuning ViT-base.

2.17 TEMAT 17 - Multimodalność – CLIP (2021)

Artykuł: <https://arxiv.org/pdf/2103.00020.pdf>

Repozytorium: <https://github.com/openai/CLIP>

Opis: CLIP jest modelem multimodalnym uczonym na dużych zbiorach par obraz–tekst w celu utworzenia wspólnej przestrzeni reprezentacji dla obu modalności. Model składa się z dwóch sieci neuronowych: jednej przetwarzającej obrazy i drugiej przetwarzającej tekst, które są trenowane w sposób kontrastywny. Celem uczenia jest maksymalizacja podobieństwa reprezentacji odpowiadających sobie obrazów i opisów oraz minimalizacja podobieństwa dla par niepowiązanych. Dzięki temu model może porównywać obrazy i opisy bez konieczności trenowania specjalizowanego klasyfikatora dla konkretnego zadania. CLIP umożliwia tzw. klasyfikację zero-shot, w której model rozpoznaje nowe klasy wyłącznie na podstawie ich opisu tekstowego. Podejście to znacząco zwiększa elastyczność systemów wizji komputerowej i ogranicza potrzebę ręcznego anotowania danych. Model stanowi fundament wielu współczesnych systemów multimodalnych oraz modeli generatywnych. Analiza CLIP pozwala zrozumieć ideę uczenia kontrastywnego oraz integracji reprezentacji wizualnych i językowych w jednej przestrzeni cech.

Plan eksperymentów

- Zero-shot classification.
- Text-to-image retrieval.
- Analiza embeddingów (PCA/UMAP).
- Eksperyment z prompt engineering.

Rozszerzenie GPU: linear probing + fine-tuning adapterów.